

Задаци из Регресионе анализе

Све задатке урадити на нивоу значајности $\alpha = 5\%$.

Линеарна и нелинеарна регресија

- (cena_stana.xlsx) Дати су подаци за продају станова у Новом Саду у староградњи. Подаци су дати у табели по кварталима и то од I квартала 2017. године до II квартала 2022. године, где су цене дате у еврима по m^2 . Нацртати дијаграм растурања и записати једначину линеарне регресије. Предвидети вредност цене m^2 стана у III кварталу 2022. године (унети 44835).
- (gejzir.xlsx) У табели су дати подаци за водоскокове гејзира у Old Faithful Geyser in Yellowstone National Park за период од 1. до 4. августа 1978. године. Променљива X представља временски период ерупције водоскока, а Y време до следећег водоскока, у минутама. Да ли можемо помоћу једноструке линеарне регресије $y_i = \alpha + \beta x_i + \varepsilon_i$ да предвиђамо вредности y помоћу x ?
 - Наћи $\hat{\alpha}$ и $\hat{\beta}$.
 - Тестирати хипотезу $H_0(\beta = 0)$.
 - Наћи интервал поверења за β .
 - Наћи R^2 .
- (tezina-otkucaji_srca.xlsx) Дати су подаци везано за број откуцај срца (у минути) и тежине човека (у kg).
 - Нацртати ове податке. Да ли постоји линеарна веза између ове две променљиве?
 - Наћи $\hat{\alpha}$ и $\hat{\beta}$ и нацртати праву линеарне регресије.
 - Посматрајмо тачку (67, 40). Ако уклонимо ову тачку из табеле, како то утиче $\hat{\alpha}$ и $\hat{\beta}$?
 - Предвидети очекивану вредност y за $x = 88$. Наћи 95% интервал поверења за очекивану вредност y када је $x = 88$.
 - Предвидети број откуцаја срца за људе које имају 88kg, користећи тачкасто предвиђање и предвиђање помоћу интервала поверења. Упоредити са г).
 - Без рачунања, за које измерено X ће одговарајуће $\hat{Y}$ имати најмању дисперзију? Зашто?
- (prasina.xlsx) Посматрамо изложеност радника једне фирме прашини. Ако су радници превише изложени прашини, онда то доводи до оштећења њиховог здравља (тзв. релативни ризик). У табели се налазе подаци за девет радника за које је мерено просечна вредност изложености испитаника прашини у јединици број честица по ft^3 ($ft = foot$ је стопа, што је 30,48cm) у једној години и потом скалирано са 10^6 (број честица/ ft^3 /година : 10^6). Вредност 1.0 релативног ризика представља да особа није здравствено угрожена, док по дефиницији, очекивана вредност релативног ризика је 1.0 ако особа није изложена прашини (тј. вредност је 0). Направити линеарно регресиони модел који пролази кроз координатни почетак, где X представља изложеност прашини, а $Y = (\text{релативни ризик} - 1)$.
- (masnoca_i_krvi.xlsx) Дати су подаци о масноћи у крви у зависности од старости и тежине за 25 испитаника. Записати једначину вишеструке линеарне регресије и предвидети вредност масноће у крви за особу стару 65 година и тежине 75kg. Такође, урадити оба једнострука линеарна модела.
- (zadatak6.xlsx) За податке у табели направити вишеструки линеарни регресиони модел.
- (zadatak7.xlsx) За податке дате у табели направити вишеструки линеарни модел $y = f(x_1, x_2, x_3, x_4)$. Да ли су коефицијенти β_2 и β_3 статистички значајни? Направити редуковани модел $y = f(x_1, x_4)$. Да ли се коефицијенти у редукованом моделу разликују од коефицијената полазног вишеструког модела?
- (automobili.xlsx) Пера продаје половне аутомобиле више од 30 година. За сваког запосленог прати колико је продао аутомобила у зависности колико је дуго запослен код њега (у недељама). Направити квадратни модел и нацртати дијаграм расипања.

9. (reka.xlsx) Одредити регресиону криву облика $y_i = a \ln x_i + b + \varepsilon_i$, која представља везу између ширине реке y и максималног годишњег протицаја воде $x \left[\frac{m^3}{s} \right]$ на основу узорка до 10 река.
10. (vlaznost.xlsx) На обали залива испитује се влажност муља (у грамима воде на 100 грама суве материје). Из једне бушотине добијени подаци су представљени у еxcel табели.
- (а) Направити степени модел облика $y_i = bx_i^a + \varepsilon_i$.
- (б) Направити експоненцијални модел облика $y_i = be^{ax_i} + \varepsilon_i$.

Анализа варијансе (ANOVA)

1. (ramuk.xlsx) У фабрици текстила желе да произведу нову тканину, издржљиву и отпорну на кидање. Из ранијег искуства познато је да проценат памука доводи, бар у почетку до повећења отпорности, као и да проценат памука треба да буде између 10 и 40 процената. Фабрички инжењер одлучује да тестира пет узорка са различитим процентом памука: 15%, 20%, 25%, 30%, 35%. Након тестирања произведених комада тканине тестира на издржљивост и добијени резултати су представљени у excel табели.
 - а) (Matlab) Направити модел анализе варијансе.
 - б) (Matlab) Тестирати хипотезу о једнакој издржљивости без обзира на проценат памука у тканини. Да ли постоје разлике (по паровима) у кидању тканине за различите проценте памука (LSD тест)?
 - в) (Statistica) Да ли су испуњене претопоставке за анализу варијансе (подаци су сагласни са нормалном расподелом и хомоскедастичност)? Поновити а) и б), при чему приказати и Mean plot за различите нивое фактора. Поред LSD теста урадити Тукијев и Данканов тест, као и Шефев тест са контрастима.
2. (plata.xlsx) У САД се налазе разни салони за продају аутомобила. Извучен је узорак од 12 салона из три америчка града (Чикаго, Њу Јорк и Вашингтон) и за сваког продавца аутомобила забележено је пол, плата, број година, број килограма, компанија у којој ради и степен стручне спреме. Помоћу анализе варијансе (ANOVA) испитати утицај сваке категоријалне променљиве на плату продавца аутомобила. Урадити у програму Statistica и у Matlab по ставкама као у 1. задатку.
3. (cokolada.xlsx) ANOVA-ом испитати утицај фирме (Bambi, Stark, Ravanica, Milka) која производи чоколаде на њихову продају у 5 продавница током месец дана. Прикупљени резултати су приказани у excel табели. Урадити у програму Statistica и у Matlab по ставкама као у 1. задатку.
4. (hrana.xlsx) У једној хладњачи желе да испитају да ли има разлике у три методе паковања замрзнутог воћа и поврћа (А,В,С). За сваку методу изабран је случајан узорак обима 7 и након неког времена за свако воће/поврће из узорка испитана је количина витамина С (L-аскорбинска киселина, L-аскорбат) у $mg/100g$. Да ли постоје статистичке разлике у присуству количине витамина С у зависности од методе паковања замрзнутог воћа и поврћа? Урадити у програму Statistica и у Matlab по ставкама као у 1. задатку.
5. (deterdzent.xlsx) Желимо да испитамо како утиче детерџент и температура воде на уклањање мрљи са веша. У табели су дати два типа детерџента, као и њихов учинак при отклањању мрљи са веша на хладној, млакој и врућој води.
 - а) (Matlab) Направити двофакторски модел анализе варијансе, где су фактори тип детерџента и температура воде, а меримо количину уклоњених мрља са веша.
 - б) (Matlab) Прво проверити да ли постоји интеракција између ова два фактора, тј. да ли су ова два фактора у некој зависности. Тестирати хипотезу о једнаком дејству оба детерџента на уклањања мрља са прљавог веша. Потом тестирати хипотезу да температура не утиче на уклањања мрља са прљавог веша.
 - в) (Statistica) Да ли су испуњене претопоставке за анализу варијансе (подаци су сагласни са нормалном расподелом и хомоскедастичност)? Поновити а) и б), при чему приказати и Mean plot за различите нивое фактора.
6. (data.crop.xlsx) Истражујемо како тип ђубрива и густина сађења паприке утиче на њен принос. Имамо три типа ђубрива (енг. fertilizer; 1, 2 и 3), две различите густине садње (енг. density; 1-ретко и 2-густо) и меримо принос (енг. yield) паприке у јединици тона (t) по хектару (ha). Помоћу двофакторске анализе варијансе испитати утицај ђубрива и густине сађења паприке на њен принос.
 - а) (Matlab) Направити двофакторски модел анализе варијансе.

- б) (Matlab) Прво проверити да ли постоји интеракција између ова два фактора, тј. да ли су ова два фактора у некој зависности. Тестирати хипотезу да тип ђубрива не утиче на принос паприке. Потом тестирати хипотезу да густина садње паприке не утиче на њен принос.
- в) (Statistica) Да ли су испуњене претопоставке за анализу варијансе (подаци су сагласни са нормалном расподелом и хомоскедастичност)? Поновити а) и б), при чему приказати и Mean plot за различите нивое фактора.

[За извршавање овог експеримента посматране су паприке засађене на четири различите њиве (у табели енг. blocks; 1, 2, 3 и 4).]